

NPU 스케줄러 Priority 실험 보고서

Hailo - 8L NPU 환경에서의 모델 우선순위 스케줄링 성능 측정

성명	전정민	학번	2022113570
작성일	2026. 6.	구분	연구실 실험 증빙자료

1. 실험 개요

본 실험은 Raspberry Pi 5에 장착된 Hailo - 8L NPU 환경에서 여러 딥러닝 모델을 동시에 추론할 때, 모델별 우선순위(priority) 설정이 추론 지연시간(latency) 및 시스템 자원 사용에 미치는 영향을 측정하는 것을 목적으로 한다. 객체 검출(Detection), 분할(Segmentation), 자세 추정(Pose) 세 가지 YOLOv8 모델을 대상으로 하였다.

2. 실험 환경

하드웨어	Raspberry Pi 5 + Hailo - 8L NPU
대상 모델	YOLOv8 Detection / Segmentation / Pose (.hef)
스케줄러	HailoRT Round - Robin 스케줄러
검증 데이터	COCO val2017 이미지 (모델당 100장)
전처리	Letterbox (비율 유지 resize + 패딩, 640×640)

3. 실험 구성

모델 조합(단일 1개 / 2개 / 3개 동시)과 priority 값(0, 15, 31)을 조합하여 총 63개 조건을 구성하고, 각 조건을 3회 반복 실행하였다(총 189회). 측정 신뢰도 확보를 위해 동일 이미지 · 동일 순서로 반복하였으며, 결과는 조건별 평균 및 표준편차로 정리하였다.

4. 측정 지표

각 실험에서 다음 항목을 측정하였다. 추론 지연시간(전처리를 제외한 순수 추론 구간만 측정), CPU · 메모리 사용률, NPU 활용률, 그리고 추론 프로세스의 context switch (자발적/비자발적 구분)이다.

5. 주요 결과

- ① Priority Starvation: 한 모델의 priority가 경쟁 모델보다 15 이상 낮을 경우, 해당 모델은 NPU 스케줄링 기회를 거의 얻지 못하는 starvation 현상이 관측되었다.
- ② Priority의 동작 특성: priority는 처리량 비율을 세밀하게 조절하는 값이 아니라, starvation 발생 여부를 결정하는 임계(threshold)에 가깝게 동작하였다. 예컨대 priority 15와 31은 NPU를 대등하게 공유하며 동시에 종료되었다.
- ③ Context Switch: 추론 스레드는 NPU 출력 대기로 인한 자발적(voluntary) context switch가 지배적이었으며, 그 수는 동시 실행 모델 수에 비례해 증가하였다(1개 약 3.7만 → 3개 약 11만 회). 이는 본 워크로드가 CPU 연산 경합보다 NPU I/O 대기 중심임을 보여준다.

④ 측정 안정성: 동일 조건 3회 반복 간 latency 표준편차가 매우 작아(예: 0.01 수준) 실험의 재현성이 높음을 확인하였다.

6. 결론

HailoRT Round - Robin 스케줄러에서 priority는 모델 간 처리 비율을 정밀 조절하기보다 starvation 방지를 위한 임계값으로 작동함을 실증하였다. 추론 latency 및 context switch 측정 코드와 실험 자동화 · 결과 정리 파이프라인을 구축하였으며, 측정 결과는 향후 다중 모델 NPU 스케줄링 분석의 기초 자료로 활용 가능하다.